

Rozpoznawanie znaków drogowych

Mateusz Rupociński, Michał Mikołajczyk

9 czerwca 2023

Spis treści

1	Opis rzeczywistego problemu	1
2	State of art	1
3	Opis wybranej koncepcji	2
3.0.1	Schemat programu	3

1 Opis rzeczywistego problemu

Cel:

Celem rozwiązania problemu rozpoznawania znaków drogowych jest stworzenie systemu, który będzie w stanie poprawnie identyfikować znaki drogowe w czasie rzeczywistym, co pozwoli na zwiększenie bezpieczeństwa na drogach.

Motywacja:

Rozwiązanie tego problemu jest istotne ze względu na rosnącą liczbę wypadków drogowych spowodowanych nieprzestrzeganiem znaków drogowych. Rozpoznawanie znaków drogowych przez sztuczną inteligencję może pomóc w zapobieganiu takim wypadkom poprzez bezpośrednie wprowadzenie ograniczeń nakładanych przez znak do ustawień samochodu oraz ułatwić pracę kierowcom, których percepcja często spada wraz z czasem szczególnie w przypadku jazdy w nieznanym miejscu.

Dane wejściowe:

Do rozwiązania problemu rozpoznawania znaków drogowych potrzebne są zdjęcia lub nagrania wideo z kamery umieszczonej na pojeździe. Dane te muszą być przetworzone w celu wyodrębnienia znaków drogowych i ich klasyfikacji. Zagadnienia z zakresu sztucznej inteligencji: Rozpoznawanie znaków drogowych to problem z zakresu widzenia komputerowego, w którym wykorzystywane są różne techniki sztucznej inteligencji, takie jak uczenie maszynowe, sieci neuronowe czy głębokie uczenie.

2 State of art

1. Metoda oparta na klasyfikacji obrazów przy użyciu sieci neuronowych - jedna z najpopularniejszych metod to wykorzystanie sieci konwolucyjnych, które są w stanie nauczyć się rozpoznawać kształt i wzór znaków drogowych. Wadą tej metody jest potrzeba dużej ilości danych do treningu sieci,

co może stanowić trudność w przypadku braku odpowiednio dużych zbiorów danych.

2. Metoda oparta na wykrywaniu krawędzi i kształtów - ta metoda wykorzystuje algorytmy przetwarzania obrazów do wykrywania krawędzi i kształtów znaków drogowych. Następnie za pomocą algorytmów klasyfikacji, np. SVM, można dokonać identyfikacji znaków. Wadą tej metody jest konieczność ręcznego określenia cech znaków drogowych, co może prowadzić do trudności w przypadku występowania znaków o zbliżonych kształtach.
3. Metoda oparta na wykorzystaniu głębokiego uczenia - ta metoda polega na zastosowaniu sieci neuronowych z wieloma warstwami, które są w stanie nauczyć się rozpoznawać znaki drogowe na podstawie obrazów. Wadą tej metody jest konieczność dużej mocy obliczeniowej oraz potrzeba dużej ilości danych do treningu sieci.
4. Metoda oparta na uczeniu maszynowym - Zaletą uczenia maszynowego jest zdolność do osiągnięcia wysokiej dokładności w rozpoznawaniu znaków drogowych. Modele uczenia maszynowego mogą być trenowane, aby radziły sobie z różnymi warunkami oświetleniowymi, perspektywą, zniszczeniami znaków drogowych itp. Dzięki temu są bardziej elastyczne i mogą działać w różnych sytuacjach drogowych. Największą wadą jest Efektywność modelu uczenia maszynowego zależy od jakości danych treningowych. Jeśli dane są nieodpowiednio oznakowane, niedoskonałe lub niepełne, to może wpływać na skuteczność.

3 Opis wybranej koncepcji

Jako środek do rozwiązania naszego problemu postanowiliśmy przyjąć uczenie maszynowe. Rozwiązanie problemu rozpoznawania znaków drogowych przy użyciu uczenia maszynowego opiera się na wykorzystaniu algorytmów klasyfikacji obrazów. Polega to na nauczaniu modelu uczenia maszynowego, który na podstawie zdjęć i etykiet (oznaczeń) określających, jakie znaki drogowe znajdują się na tych zdjęciach, będzie w stanie rozpoznawać nowe, nieznane mu wcześniej znaki drogowe.

W celu rozwiązania tego problemu potrzebne są dane wejściowe w postaci zbioru zdjęć zawierających znaki drogowe oraz etykiet, które informują, jakie znaki drogowe znajdują się na zdjęciach. Jako naszą bazę danych wykorzystaliśmy German Traffic Sign Recognition Benchmark (GTSRB), który zawiera ponad 50 000 zdjęć zawierających 43 różne znaki drogowe. Po wyuczeniu modelu, można go wykorzystać do rozpoznawania znaków drogowych na nowych zdjęciach. Proces ten polega na podaniu zdjęcia do modelu, który dokonuje klasyfikacji obrazu i zwraca etykietę znaku drogowego, który został na nim przedstawiony, w naszym projekcie udało się osiągnąć 95% dokładność w rozpoznawaniu znaków:

```
test_xd
Epoch 1/15
981/981 [.....] - 584s 594es/step - loss: 1.4986 - accuracy: 0.6641 - val_loss: 0.1979 - val_accuracy: 0.9583
Epoch 2/15
24/981 [.....] - ETA: 8:08 - loss: 0.4772 - accuracy: 0.8711
```

3.0.1 Schemat programu

Schemat działania modelu(Poniższa pętla wykonuje się dwukrotnie ze zmienionymi parametrami przy kolejnej iteracji):

1. W pierwszym kroku przepuszczamy obrazy przez dwie warstwy konwulucyjne(rodzaj algorytmu głębokiego uczenia, który jest najczęściej stosowany do analizy i poznawania cech wizualnych w oparciu o duże ilości danych.)
2. Następnie wykorzystujemy funkcję Max Pooling 2D która służy do redukcji rozmiarów przestrzennych map cech.
3. W kolejnym kroku aby "nieprzeuczyć"naszego modelu wykorzystujemy warstwę Dropout która odrzuca losową zadaną ilość próbek (u nas 25

Po zakończeniu wykonywania cyklu uczenia program zapisuje sobie dane i jest gotowy do działania.